# MVP – Engenharia de Dados

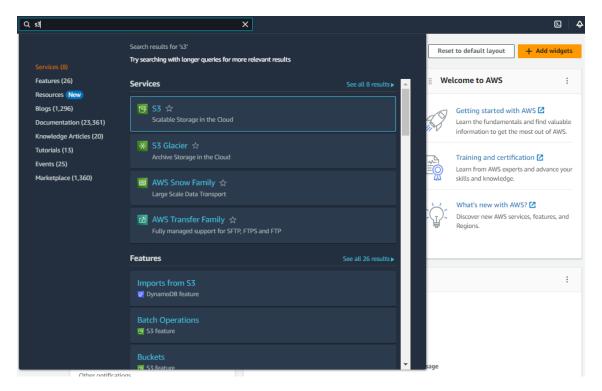
#### Josafá de Sousa Gomes Júnior

### 1. Objetivo

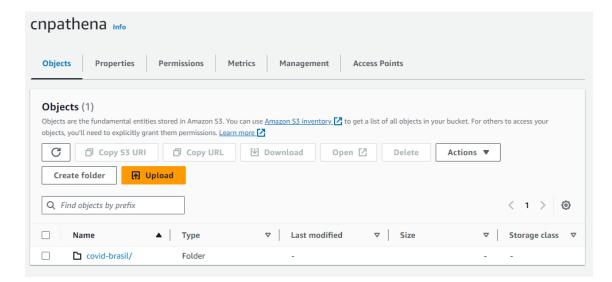
Com os dados obtidos da nuvem e uso de SQL, iremos retirar alguns insights que serão mostrados diretamente do banco contendo dados da Covid 19 no Brasil retirados do website <a href="https://brasil.io/dataset/covid19/files/">https://brasil.io/dataset/covid19/files/</a>. O arquivo que foi feito o tratamento está no formato CSV.

#### 2. Modelagem

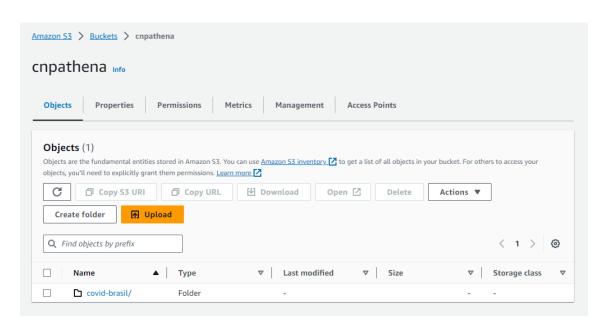
AWS Glue e Amazon Athena serão usados para fazer a leitura dos dados e realizar queries para extrair informações desejadas dos bancos de forma a extrair o que pode ser agregador na leitura e entendimento do mesmo.



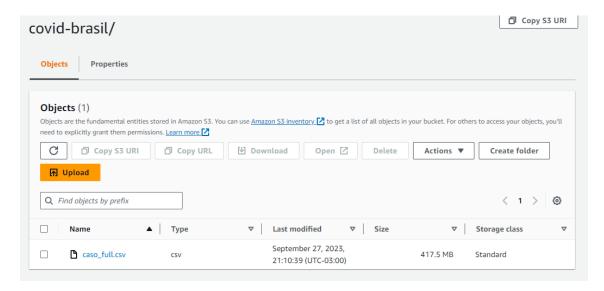
Acessar o S3 e criar um bucket



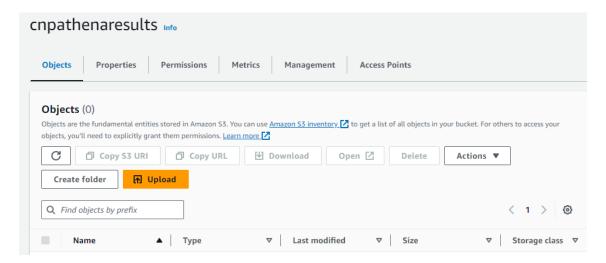
Nome dado ao bucket: cnpathena



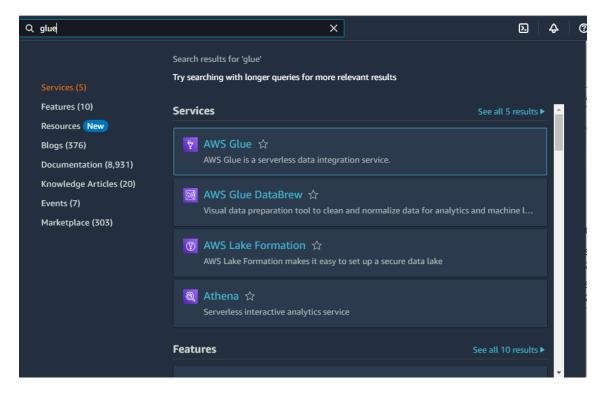
Criada uma pasta dentro do bucket chamada: covid-brasil



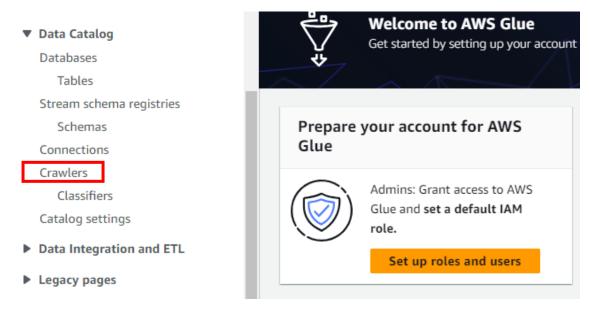
Feito o upload do arquivo csv na pasta covid-brasil (tamanho: 417.5 MB)



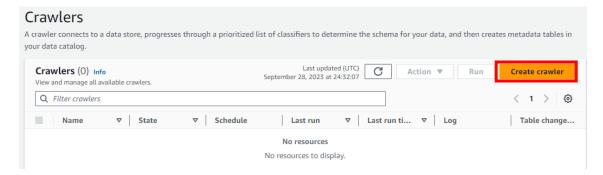
Novo bucket criado e adicionado para armazenar os resultados da query



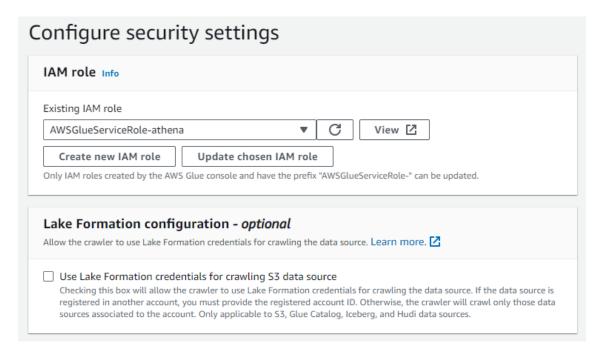
Acessar o AWS Glue para fazer a parte de ETL (Tratamento de dados) com o uso de Crawlers



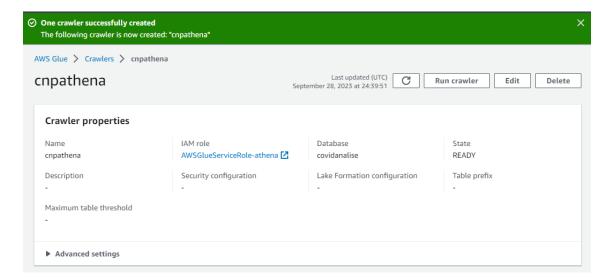
Inspeciona os arquivos do bucket e pega os arquivos csv para criar uma tabela



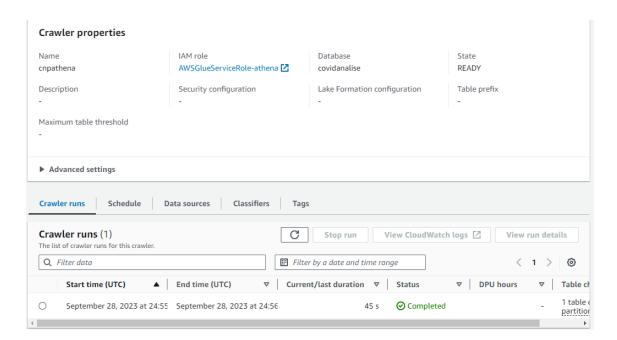
Início do processo de configuração para criar o crawler



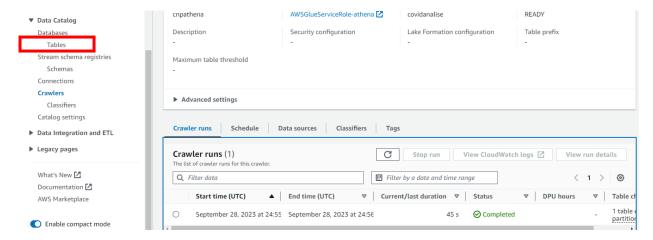
Nomear o IAM para habilitar a comunicação entre os serviços, ou seja, com o S3



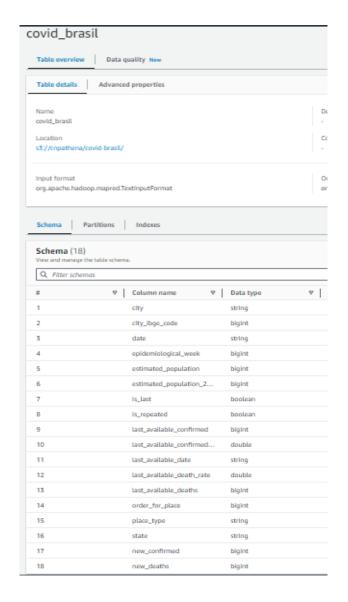
Tela mostrando que o crawler foi criado com sucesso



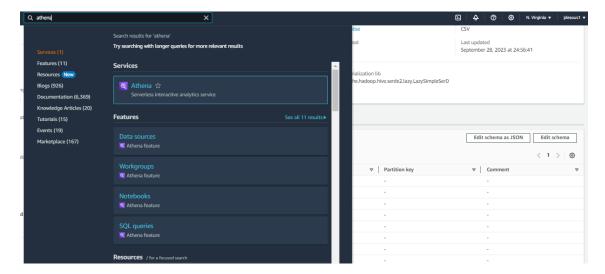
Após clicar em "Run Crawler" o arquivo é executado no mesmo



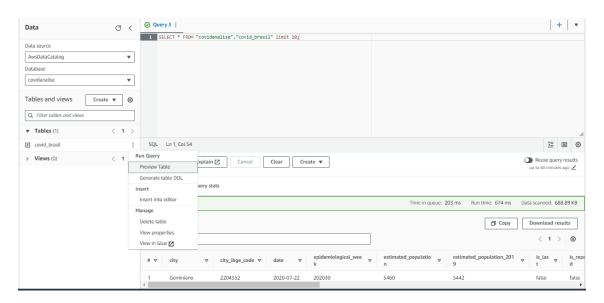
Passo seguinte é clicar em tabelas



O esquema mostrado apresenta as colunas presentes no arquivo e os tipos de variáveis contidos nele



Passo seguinte é acessar o Athena para fazer queries no arquivo csv



Antes de rodar a query, configurar onde o Athena irá fazê-lo, dessa forma o Athena ficará configurado e poderá ser exibido do lado esquerdo a tabela covid\_brasil, clicando nos três pontos e em "preview table", é possível rodar um preview da tabela.

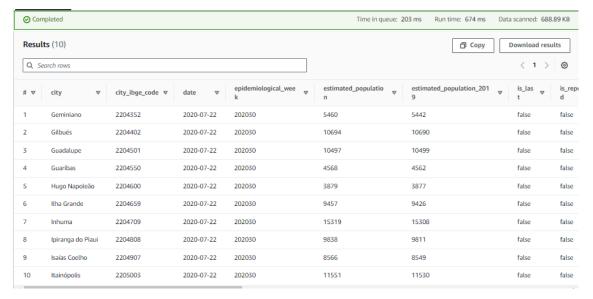
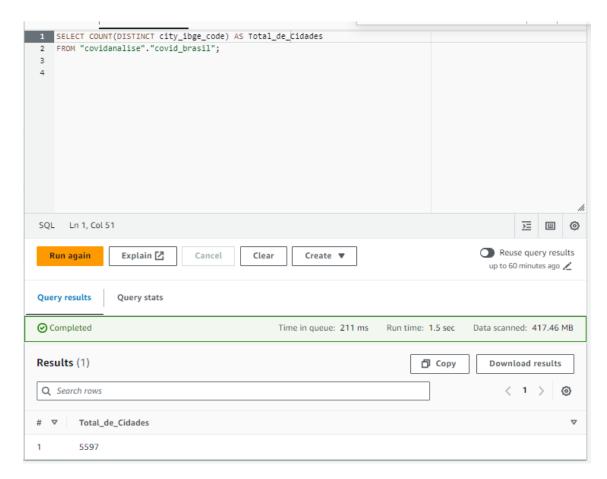


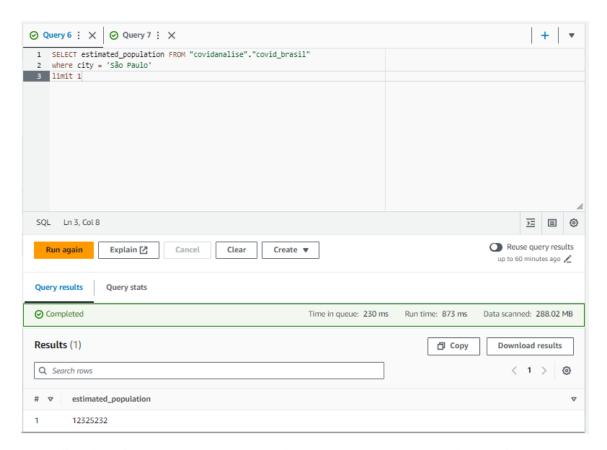
Tabela criada a partir da query executada

## 3. Solução do Problema

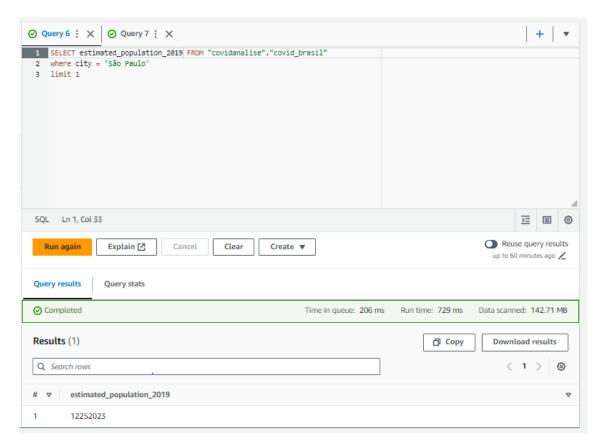
A partir da modelagem realizada vamos retirar insights dos dados modelados. Aplicando SQL temos as seguintes informações:



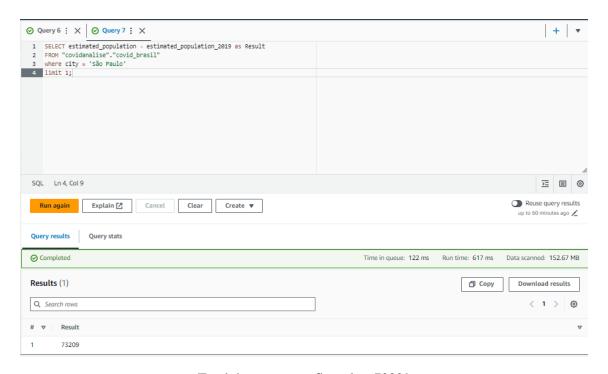
Total de cidades afetadas pela Covid 19 com base na tabela exploradas



Analisando a cidade de São Paulo dentro da amostra, temos que a população estimada até a data da última coleta de dados é de 12.325.232 habitantes



A população estimada em 2019 era de 12.252.023 habitantes



Total de mortes confirmadas: 73209